数理工学実験レポート

第 3 章（最小二乗法）

学籍番号 1029366161　　中塚一瑳

2025 年 11 月 3 日

概要

目次

1　はじめに

本実験第 2 回では，最小二乗法の基礎とその実装手法を学ぶことを目的とする。具体的には，観測データからのパラメータ推定，重み付き・逐次最小二乗法，データ分割・推定値の合成を通して，推定精度と計算効率の違いを実験的に比較する。

2　最小二乗法とその評価方法

2.1　原理・方法

観測モデルを

$$y_i = f(\theta, x_i) + w_i \tag{1}$$

とする．加法雑音 w_i は平均 0，観測ごとに独立，同一分布であり，共分散は有限と仮定する．ここでは $f(\theta, x) = \phi(x)\theta$ としてパラメータに対して線形とし，最小二乗問題

$$\min_{\theta} \sum_{i=1}^{N} \|y_i - \phi(x_i)\theta\|^2 \tag{2}$$

を解く．解は

$$\hat{\theta}_N = \Big(\sum_{i=1}^{N} \phi_i^\top \phi_i \Big)^{-1} \sum_{i=1}^{N} \phi_i^\top y_i, \qquad \phi_i := \phi(x_i). \tag{3}$$

また雑音分散が未知の場合の推定量および推定誤差共分散は

$$\hat{\sigma}^2 = \frac{1}{N-n} \sum_{i=1}^{N} \|y_i - \phi_i \hat{\theta}_N\|^2, \tag{4}$$

$$\widehat{\mathrm{Cov}}(\hat{\theta}_N) = \hat{\sigma}^2 \Big(\sum_{i=1}^{N} \phi_i^\top \phi_i \Big)^{-1} \tag{5}$$

で与えられる．

当てはまりの評価には決定係数

$$C = \frac{\sum_{i=1}^{N} \|\phi_i \hat{\theta}_N - \bar{y}\|^2}{\sum_{i=1}^{N} \|y_i - \bar{y}\|^2}, \qquad \bar{y} = \frac{1}{N} \sum_{i=1}^{N} y_i \tag{6}$$

を用いる．以上は資料 3.2 の線形最小二乗および評価に対応する．

本実験では $\phi(x)$ として設計した特徴量から行列

$$X = \begin{bmatrix} \phi(x_1)^\top \\ \vdots \\ \phi(x_N)^\top \end{bmatrix} \tag{7}$$

を構成し，観測データを

$$y = [y_1; \ldots; y_N] \tag{8}$$

として用いる．パラメータ推定量は

$$\hat{\theta} = (X^\top X)^{-1} X^\top y \tag{9}$$

で与えられる．

残差は

$$r = y - X\hat{\theta} \tag{10}$$

とし，雑音分散推定量は

$$\hat{\sigma}^2 = \frac{\|r\|^2}{N - p} \tag{11}$$

（p は列数）とする．

パラメータ推定の誤差共分散は

$$\hat{\sigma}^2 (X^\top X)^{-1} \tag{12}$$

で与えられる．

決定係数は

$$C = \frac{\|X\hat{\theta} - \bar{y}\mathbf{1}\|^2}{\|y - \bar{y}\mathbf{1}\|^2} \tag{13}$$

と定義する．

以下の R 関数が上記推定を実装している．

```
regression_simple <- function(x, y){
    theta_hat  <- solve(t(x) %*% x) %*% t(x) %*% y
    sigma2_hat <- as.numeric(t(y - x %*% theta_hat) %*%
                             (y - x %*% theta_hat) /
                             (nrow(x) - ncol(x)))
    err_cov_mat <- sigma2_hat * solve(t(x) %*% x)
    det_coef <- sum((x %*% theta_hat - mean(y))^2) /
                sum((y - mean(y))^2)
    list(theta_hat=theta_hat, err_cov_mat=err_cov_mat,
         sigma2_hat=sigma2_hat, det_coef=det_coef)
}
```

2.2 課題 1（重回帰）

■モデル $y_i = x_i^\top \theta + w_i$ $(i = 1, \ldots, N)$．$x_i \in \mathbb{R}^2$．w_i は独立，同分散 σ^2，平均 0．$X = [x_1^\top; \ldots; x_N^\top] \in \mathbb{R}^{N \times 2}$，$y = [y_1; \ldots, y_N] \in \mathbb{R}^N$．

■推定量 最小二乗推定量

$$\hat{\theta}_N = (X^\top X)^{-1} X^\top y.$$

残差 $r = y - X\hat{\theta}_N$ により

$$\hat{\sigma}^2 = \frac{\|r\|_2^2}{N - p}, \quad p = 2, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_N) = \hat{\sigma}^2 \, (X^\top X)^{-1}.$$

決定係数

$$R^2 = \frac{\|X\hat{\theta}_N - \bar{y}\mathbf{1}\|_2^2}{\|y - \bar{y}\mathbf{1}\|_2^2}, \quad \bar{y} = \frac{1}{N} \sum_{i=1}^{N} y_i.$$

■収束確認　$N \in \{2, 4, 8, \ldots, 2^{13} = 8192\}$ で $\hat{\theta}_N$ を計算し，N を横軸とする片対数図で各成分を同一図に描く．

■結果（全データ $N = 10000$）

$$\hat{\theta}_N = \begin{bmatrix} 1.506551 \\ 1.997696 \end{bmatrix}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_N) = \begin{bmatrix} 9.866491 \times 10^{-5} & -4.081657 \times 10^{-7} \\ -4.081657 \times 10^{-7} & 1.005248 \times 10^{-4} \end{bmatrix}.$$

決定係数

$$R^2 = 0.8629734.$$

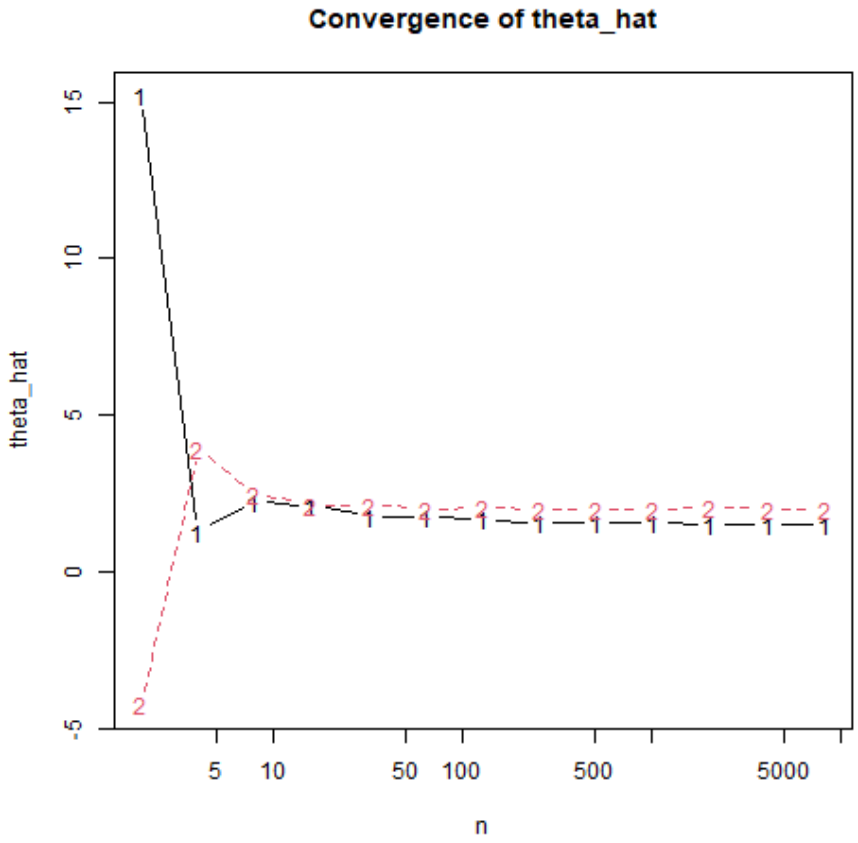

図 1: $\hat{\theta}_N$ の収束（横軸 $N = 2, 4, \ldots, 8192$ の片対数）

■R コード

```r
# データ読み込み
data <- read.csv("datas/mmse_kadai1.csv", header=FALSE,
                 col.names = c("x1","x2","y"))
x <- as.matrix(data[, c("x1","x2")])
y <- as.matrix(data[, "y"])

# 最小二乗（原理・方法で用いる関数）
regression_simple <- function(x, y){
  theta_hat  <- solve(t(x) %*% x) %*% t(x) %*% y
  sigma2_hat <- as.numeric(t(y - x %*% theta_hat) %*%
                           (y - x %*% theta_hat) / (nrow(x) - ncol(x)))
  err_cov_mat <- sigma2_hat * solve(t(x) %*% x)
```

```r
  det_coef <- sum((x %*% theta_hat - mean(y))^2) /
              sum((y - mean(y))^2)
  list(theta_hat=theta_hat, err_cov_mat=err_cov_mat,
       sigma2_hat=sigma2_hat, det_coef=det_coef)
}

# 部分データでの実験
exp1 <- function (x, y, n){
  x <- x[1:n, , drop=FALSE]
  y <- y[1:n, , drop=FALSE]
  result <- regression_simple(x, y)
  list(theta_hat = result$theta_hat,
       err_cov_mat = result$err_cov_mat,
       det_coef = result$det_coef)
}

# 収束図の作成
plot_exp1 <- function(x, y, out="graphs/task1.png"){
  ns <- 2^(1:13)  # 2,...,8192
  theta_hats <- matrix(NA_real_, nrow=length(ns), ncol=ncol(x))
  for(i in seq_along(ns)){
    theta_hats[i, ] <- as.vector(exp1(x, y, ns[i])$theta_hat)
  }
  dir.create(dirname(out), showWarnings=FALSE, recursive=TRUE)
  png(out, width=960, height=600, res=120)
  matplot(ns, theta_hats, type="b", log="x",
          xlab="N", ylab=expression(hat(theta)),
          main="Convergence of OLS estimates")
  legend("bottomright",
         legend=paste0("theta[", 1:ncol(x), "]"),
         lty=1:ncol(x), pch=1:ncol(x))
  dev.off()
}

# 実行例（全データ）
N_max <- nrow(x)
th   <- exp1(x, y, N_max)$theta_hat
Vhat <- exp1(x, y, N_max)$err_cov_mat
R2   <- exp1(x, y, N_max)$det_coef
print(th); print(Vhat); print(R2)

# 収束図
plot_exp1(x, y)
```

■考察

2.3 課題 2（多項式回帰）

■モデル $y_i = \varphi(x_i)\theta + w_i,\quad \varphi(x) = [1\ x\ x^2\ x^3],\ i = 1,\dots,N.$ 雑音 w_i は独立，同分散 σ^2，平均 0．$X = [\varphi(x_1);\dots;\varphi(x_N)] \in \mathbb{R}^{N\times 4}$.

■推定量 推定量・共分散・決定係数は課題 1 と同じ形式（$p = 4$）で計算する．

■収束確認　$N \in \{4, 8, 16, \ldots, 8192\}$ で $\hat{\theta}_N$ を計算し，N を横軸とする片対数図で各成分を同一図に描画する．

■結果（全データ $N = 10000$）

$$\hat{\theta}_N = \begin{bmatrix} -0.50902942 \\ 1.97586067 \\ 0.19774405 \\ -0.09866691 \end{bmatrix}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_N) = \begin{bmatrix} 2.023442 \times 10^{-3} & -1.186497 \times 10^{-5} & -1.348312 \times 10^{-4} & 3.97116 \\ -1.186497 \times 10^{-5} & 6.753015 \times 10^{-4} & -1.898545 \times 10^{-7} & -3.79471 \\ -1.348312 \times 10^{-4} & -1.898545 \times 10^{-7} & 1.603910 \times 10^{-5} & 6.35182 \\ 3.971165 \times 10^{-7} & -3.794719 \times 10^{-5} & 6.351820 \times 10^{-8} & 2.52871 \end{bmatrix}$$

標準誤差（対角の平方根）：$\mathrm{SE}(\hat{\theta}_0) \approx 0.0450$，$\mathrm{SE}(\hat{\theta}_1) \approx 0.0260$，$\mathrm{SE}(\hat{\theta}_2) \approx 0.00400$，$\mathrm{SE}(\hat{\theta}_3) \approx 0.00159$.

決定係数：

$$R^2 = 0.461855.$$

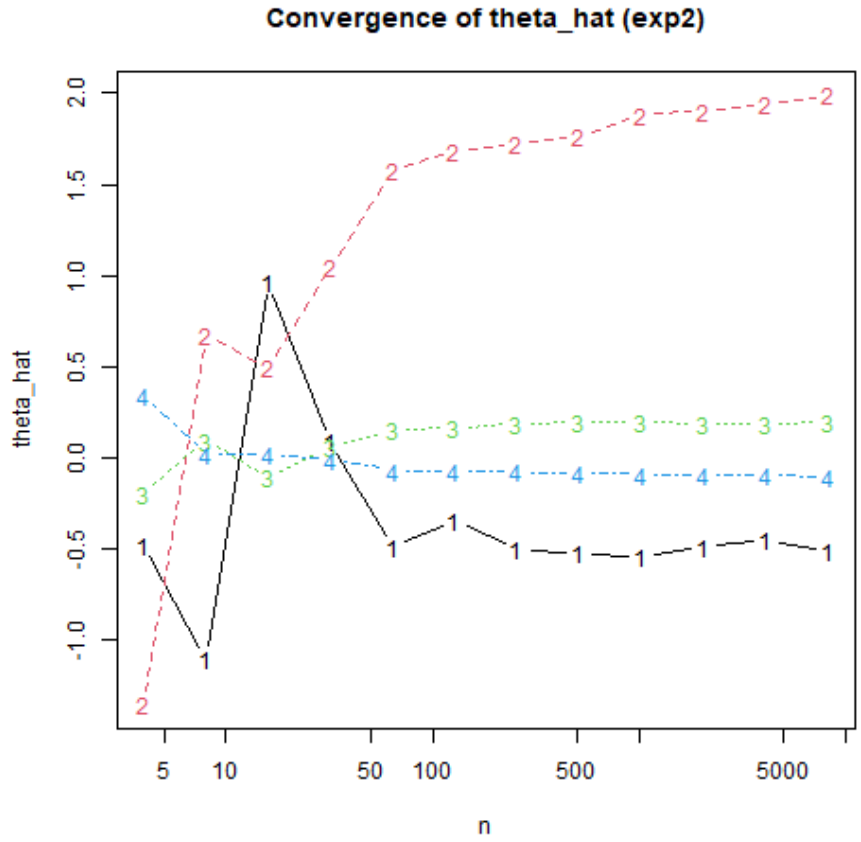

図 2: $\hat{\theta}_N$ の収束（横軸 $N = 4, 8, \ldots, 8192$ の片対数）

■R コード

```r
# データ
data <- read.csv("datas/mmse_kadai2.csv", header=FALSE,
                 col.names=c("x1","y"))
x0 <- rep(1, nrow(data))
x1 <- as.matrix(data["x1"])
x2 <- x1^2; x3 <- x1^3
x  <- cbind(x0, x1, x2, x3)
```

```r
y  <- as.matrix(data[,"y"])

# OLS 基本関数（課題1と同じ）
regression_simple <- function(x, y){
  theta_hat  <- solve(t(x) %*% x) %*% t(x) %*% y
  sigma2_hat <- as.numeric(t(y - x %*% theta_hat) %*%
                           (y - x %*% theta_hat) / (nrow(x) - ncol(x)))
  err_cov_mat <- sigma2_hat * solve(t(x) %*% x)
  det_coef <- sum((x %*% theta_hat - mean(y))^2) /
              sum((y - mean(y))^2)
  list(theta_hat=theta_hat, err_cov_mat=err_cov_mat,
       sigma2_hat=sigma2_hat, det_coef=det_coef)
}

# 部分データ実験
exp2 <- function(x, y, n){
  x <- x[1:n, , drop=FALSE]
  y <- y[1:n, , drop=FALSE]
  result <- regression_simple(x, y)
  list(theta_hat=result$theta_hat,
       err_cov_mat=result$err_cov_mat,
       det_coef=result$det_coef)
}

# 収束図
plot_exp2 <- function(x, y, out="graphs/task2.png"){
  ns <- 2^(2:13)  # 4,...,8192
  theta_hats <- matrix(NA_real_, nrow=length(ns), ncol=ncol(x))
  for(i in seq_along(ns)){
    theta_hats[i, ] <- as.vector(exp2(x, y, ns[i])$theta_hat)
  }
  dir.create(dirname(out), showWarnings=FALSE, recursive=TRUE)
  png(out, width=960, height=600, res=120)
  matplot(ns, theta_hats, type="b", log="x",
          xlab="N", ylab=expression(hat(theta)),
          main="Convergence of OLS estimates (poly degree 3)")
  legend("bottomright",
         legend=paste0("theta[",0:(ncol(x)-1),"]"),
         lty=1:ncol(x), pch=1:ncol(x))
  dev.off()
}

# 実行例
N_max <- nrow(x)
print(exp2(x, y, N_max)$theta_hat)
print(exp2(x, y, N_max)$err_cov_mat)
print(exp2(x, y, N_max)$det_coef)
plot_exp2(x, y)
```

■考察

2.4 課題 3（分散の観測誤差：Cauchy）

■モデルと注意 $y_i = x_i^\top \theta + w_i$ $(i = 1, \ldots, N)$，$x_i \in \mathbb{R}^2$．観測誤差 $w_i \sim \mathrm{Cauchy}(0, 1)$ 独立同分布．Cauchy は二乗可積分でないため $\mathbb{E}[w_i^2]$ が存在せず，最小二乗法の通常仮定（有限分散と大数の

法則）は満たされない。よって σ^2 や $\mathrm{Cov}(\hat{\theta})$ は理論上定義できない。以下の分散・標準誤差・R^2 は便宜的な値であり，統計的保証はない。

■推定（形式的な OLS） 推定量・共分散・決定係数は課題 1 と同じ形式（$p = 2$）で計算する．ただし観測誤差が Cauchy 分布であり理論保証がないことに注意.

■結果（全データ $N = 10000$）

$$\hat{\theta}_N = \begin{bmatrix} 2.373074 \\ 1.537311 \end{bmatrix}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_N) = \begin{bmatrix} 9.234588215 & -0.003642121 \\ -0.003642121 & 9.264075136 \end{bmatrix}.$$

参考：対角の平方根は $\mathrm{SE}(\hat{\theta}_1) \approx 3.0388$, $\mathrm{SE}(\hat{\theta}_2) \approx 3.0437$. 決定係数（参考値）は

$$R^2 = 0.0002841468.$$

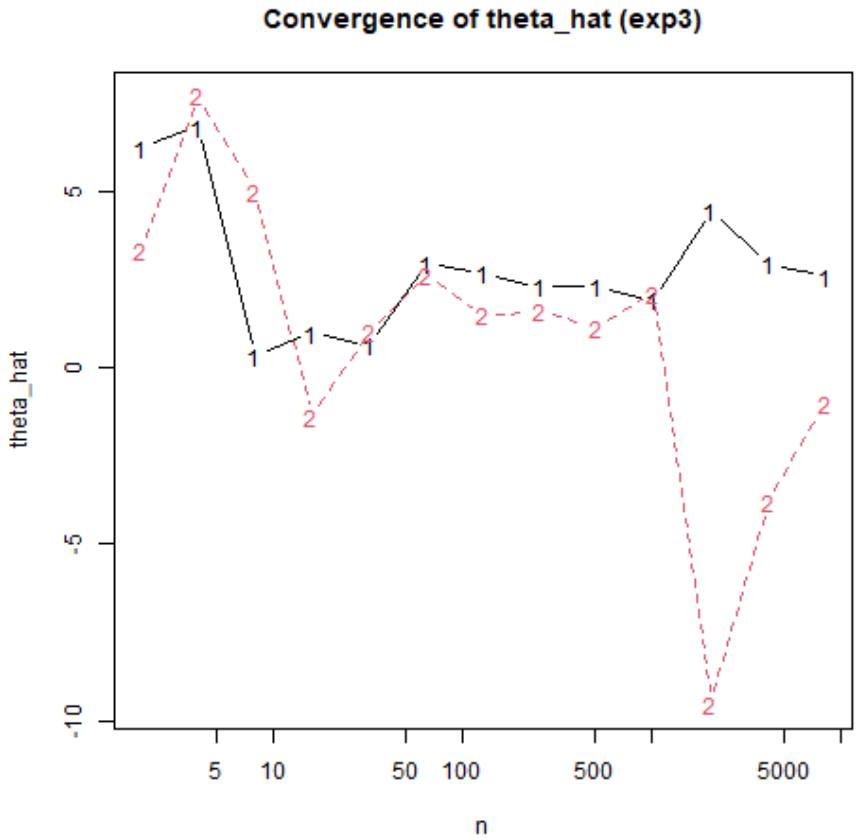

図 3: $\hat{\theta}_N$ の非収束例（横軸 $N = 2, 4, \ldots, 8192$ の片対数）

■R コード

```r
# データ読込
data3 <- read.csv("datas/mmse_kadai3.csv", header=FALSE,
                  col.names=c("x1","x2","y"))
x <- as.matrix(data3[, c("x1","x2")])
y <- as.matrix(data3[, "y"])

# 形式的なOLS（課題1と同様）
regression_simple <- function(x, y){
```

```r
  theta_hat  <- solve(t(x) %*% x) %*% t(x) %*% y
  sigma2_hat <- as.numeric(t(y - x %*% theta_hat) %*%
                           (y - x %*% theta_hat) / (nrow(x) - ncol(x)))
  err_cov_mat <- sigma2_hat * solve(t(x) %*% x)
  det_coef <- sum((x %*% theta_hat - mean(y))^2) /
              sum((y - mean(y))^2)
  list(theta_hat=theta_hat, err_cov_mat=err_cov_mat,
       sigma2_hat=sigma2_hat, det_coef=det_coef)
}

# 部分データでの実験
exp3 <- function(x, y, n){
  x <- x[1:n, , drop=FALSE]
  y <- y[1:n, , drop=FALSE]
  res <- regression_simple(x, y)
  list(theta_hat=res$theta_hat,
       err_cov_mat=res$err_cov_mat,
       det_coef=res$det_coef)
}

# 収束図
plot_exp3 <- function(x, y, out="graphs/task3.png"){
  ns <- 2^(1:13)                        # 2,...,8192
  ns <- ns[ns <= nrow(x)]
  theta_hats <- matrix(NA_real_, nrow=length(ns), ncol=ncol(x))
  for(i in seq_along(ns)){
    theta_hats[i, ] <- as.vector(exp3(x, y, ns[i])$theta_hat)
  }
  dir.create(dirname(out), showWarnings=FALSE, recursive=TRUE)
  png(out, width=960, height=600, res=120)
  matplot(ns, theta_hats, type="b", log="x",
          xlab="N", ylab=expression(hat(theta)),
          main="Convergence of OLS under Cauchy noise")
  legend("topright", legend=paste0("theta[",1:ncol(x),"]"),
         lty=1:ncol(x), pch=1:ncol(x))
  dev.off()
}

# 実行例
N_max <- nrow(x)
print(exp3(x, y, N_max)$theta_hat)
print(exp3(x, y, N_max)$err_cov_mat)
print(exp3(x, y, N_max)$det_coef)
plot_exp3(x, y)
```

■考察　資料にあるように、Cauchy 誤差では外れ値の影響が支配的で，$\hat{\theta}_N$ は N を増やしても安定しにくいことが確認できた。

2.5　課題 4（入力域の制約と設計）

■設定　課題 2 と同じ $\varphi(x) = [\,1\ x\ x^2\ x^3\,]$, 真の θ, 観測誤差 $w_i \sim \mathcal{N}(0, 9)$ とする．ただし入力は $x_i \in [0, 1]$, $i = 1, \ldots, 10000$．$X = [\varphi(x_1); \ldots; \varphi(x_N)] \in \mathbb{R}^{N\times 4}$, $y = [y_1; \ldots; y_N]$.

■推定量　推定量・共分散・決定係数は課題 1 と同じ形式（$p = 4$）で計算する．

■R コード

```r
# 課題4: x ∈ [0,1], φ(x)=[1 x x^2 x^3]
data <- read.csv("datas/mmse_kadai4.csv", header=FALSE,
                 col.names=c("x1","y"))
x0 <- rep(1, nrow(data))
x1 <- as.matrix(data[,"x1"])
x2 <- x1^2; x3 <- x1^3
x  <- cbind(x0, x1, x2, x3)
y  <- as.matrix(data["y"])

regression_simple <- function(x, y){
  theta_hat  <- solve(t(x) %*% x) %*% t(x) %*% y
  sigma2_hat <- as.numeric(t(y - x %*% theta_hat) %*%
                           (y - x %*% theta_hat) / (nrow(x) - ncol(x)))
  err_cov_mat <- sigma2_hat * solve(t(x) %*% x)
  det_coef <- sum((x %*% theta_hat - mean(y))^2) /
              sum((y - mean(y))^2)
  list(theta_hat=theta_hat, err_cov_mat=err_cov_mat,
       sigma2_hat=sigma2_hat, det_coef=det_coef)
}

exp4 <- function(x, y, n){
  x <- x[1:n, , drop=FALSE]
  y <- y[1:n, , drop=FALSE]
  regression_simple(x, y)
}

N_max <- nrow(x)
res4 <- exp4(x, y, N_max)
print(res4$theta_hat)
print(res4$err_cov_mat)
print(res4$det_coef)   # R^2
```

■結果（$N = 10000$）

$$\hat{\theta}_{(4)} = \begin{bmatrix} \boxed{\text{ここに数値}} \\ \boxed{\text{ここに数値}} \\ \boxed{\text{ここに数値}} \\ \boxed{\text{ここに数値}} \end{bmatrix}, \quad \widehat{\mathrm{Cov}}(\hat{\theta}_{(4)}) = \boxed{\text{ここに } 4\times 4 \text{ 行列}}, \quad R^2 = \boxed{\text{ここに数値}}.$$

（上の枠に，直上の R 出力を転記）

■課題 2.1 との比較（$N = 10000$） 課題 2.1 の推定結果：

$$\hat{\theta}_{(2.1)} = \begin{bmatrix} -0.50902942 \\ 1.97586067 \\ 0.19774405 \\ -0.09866691 \end{bmatrix}, \quad R^2 = 0.461855.$$

評価観点：

- 分散は $\mathrm{Var}(\hat{\theta}) = \sigma^2 (X^\top X)^{-1}$ に比例．$x \in [0,1]$ では列 $\{1, x, x^2, x^3\}$ が強く相関しやすく，$X^\top X$ の条件が悪化し $\hat{\theta}$ の不確かさが増えやすい．
- R^2 は母集団の y の散らばり（SST）に依存．入力域が狭いと SST が小さく，雑音分散が同じなら R^2 は低下しやすい．

■考察（どうデータを取るべきか）

- 目的は $\mathrm{Var}(\hat{\theta})$ の縮小（$= X^\top X$ を「大きく」「良条件」に）.
- 入力設計：x を区間全体で広く配置（例：一様），中心化・標準化して $[-1,1]$ に写像，または直交基底（Legendre/Chebyshev）で回帰.
- 最適化観点：A/D 最適設計を用いて $\mathrm{tr}((X^\top X)^{-1})$ や $\det\big((X^\top X)^{-1}\big)$ を最小化する点集合を選ぶ.

3　重み付き最小二乗法

3.1　原理と方法

■原理　各観測 $i = 1, \ldots, N$ で $y_i \in \mathbb{R}^m$, $X_i \in \mathbb{R}^{m\times p}$ とし

$$y_i = X_i\theta + w_i, \qquad \mathbb{E}[w_i] = 0,\ \mathrm{Cov}(w_i) = V \text{ (既知)},$$

を仮定する。$Q := V^{-1}$ とおく。WLS は重み付き残差平方和

$$J(\theta) = \sum_{i=1}^{N} (y_i - X_i\theta)^\top Q\,(y_i - X_i\theta)$$

を最小化する推定で，正規方程式は

$$S\hat{\theta} = b, \qquad S := \sum_{i=1}^{N} X_i^\top Q X_i, \quad b := \sum_{i=1}^{N} X_i^\top Q y_i.$$

したがって

$$\hat{\theta} = (\sum_{i=1}^{N} X_i^\top Q X_i)^{-1}\Big(\sum_{i=1}^{N} X_i^\top Q y_i\Big).$$

V が既知のとき

$$\mathrm{Cov}(\hat{\theta}) = S^{-1}.$$

$V = \sigma^2\Sigma$ のようにスケール未知なら

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{N} r_i^\top \Sigma^{-1} r_i}{Nm - p}, \quad r_i := y_i - X_i\hat{\theta}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}) = \hat{\sigma}^2\,(\sum X_i^\top \Sigma^{-1} X_i)^{-1}.$$

■方法　(1) 各 i の設計行列 X_i と観測 y_i を用意（X_i は $m \times p$）。(2) $Q = V^{-1}$ を決めて $S = \sum X_i^\top Q X_i$, $b = \sum X_i^\top Q y_i$ を計算。(3) $\hat{\theta} = S^{-1}b$。

■実装　R による実装例を以下に示す。

```
regression_multiple <- function(x, y, V = NULL, Q = NULL){
    # y: n×1行列（またはベクトル）
    if (is.null(ncol(y))) {
        y <- as.matrix(y, ncol = 1)
    }
    if (length(dim(x)) != 3) {
```

```
        stop("x must be a 3-dimensional array")
    }
    n <- dim(x)[3]
    m <- ncol(y)
    p <- dim(x)[1] # 特徴量数
    S <- matrix(0, p, p)
    b <- matrix(0, p, 1)
    T <- matrix(0, p, p)
    if (is.null(V)) {
        V <- diag(m)
    }
    if (is.null(Q)) {
        Q <- solve(V)
    }
    # m=1（スカラー出力）の場合はQ,Vをスカラー化
    if (m == 1) {
        Q <- as.numeric(Q)
        V <- as.numeric(V)
        for (i in 1:n) {
            xi <- as.matrix(x[,,i]) # (p,1)
            S <- S + xi %*% t(xi) * Q
            b <- b + xi * Q * y[i, 1]
            T <- T + xi %*% t(xi) * V
        }
    } else {
        for (i in 1:n) {
            xi <- as.matrix(x[,,i])
            yi <- matrix(y[i, ], nrow = m, ncol = 1)
            S <- S + t(xi) %*% Q %*% xi
            b <- b + t(xi) %*% Q %*% yi
            T <- T + t(xi) %*% V %*% xi
        }
    }
    theta_hat <- solve(S) %*% b
    err_cov_mat <- solve(S) %*% T %*% solve(S)
    return(list(theta_hat = theta_hat, err_cov_mat = err_cov_mat, S = S, b = b, T = T
        ))
}
```

3.2 課題 5（2 次元出力：重み付き最小二乗法）

■課題の内容　入力 $x_i \in \mathbb{R}$（$i = 1, \ldots, 1000$）に対し，$m = 2$ 次元出力の線形モデル

$$y_i \;=\; \phi(x_i)\,\theta \;+\; w_i, \qquad \phi(x) = \begin{bmatrix} 1 & x \\ 1 & x^2 \end{bmatrix}, \quad w_i \sim \mathcal{N}(0, V),\; V = \begin{bmatrix} 100 & 0 \\ 0 & 1 \end{bmatrix},$$

を考える．ここで $\theta \in \mathbb{R}^2$ を推定対象とする．

■推定法　最小二乗（OLS）の推定値は

$$\hat{\theta}_N \;=\; \Big(\sum_{i=1}^{N} \phi_i^\top \phi_i\Big)^{-1} \sum_{i=1}^{N} \phi_i^\top y_i,$$

で与えられる（$\phi_i = \phi(x_i)$）．観測雑音の共分散 V が既知で，その影響を反映した重み付き最小二乗（WLS）を用いると，$V = W^2$ を満たす W に対し

$$\hat{\theta}_N \;=\; \Big(\sum_{i=1}^{N} \phi_i^\top W^{-2} \phi_i\Big)^{-1} \sum_{i=1}^{N} \phi_i^\top W^{-2} y_i \;=\; \Big(\sum_{i=1}^{N} \phi_i^\top Q\, \phi_i\Big)^{-1} \sum_{i=1}^{N} \phi_i^\top Q\, y_i,$$

となる（$Q = W^{-2} = V^{-1}$）．

■実装　`datas/mmse_kadai5.csv` を読み込み，x から $\phi(x) = \begin{bmatrix} 1 & x \\ 1 & x^2 \end{bmatrix}$ を構成して $x \in \mathbb{R}^{2\times 2\times N}$ の 3 次元配列とし，$y \in \mathbb{R}^{N\times 2}$ を観測行列とした．推定は関数 `regression_multiple` を用い，**OLS** は無重み（$Q = I$），**WLS** は $V = \mathrm{diag}(100, 1)$ を渡し内部で $Q = V^{-1}$ を用いる設定とした．また，$N \in \{4, 8, 16, 32, 64, 128, 256, 512, 1000\}$ に対する $\hat{\theta}_N$ の収束の様子を片対数（x 軸のみ対数）で可視化した．

■結果　全データ（$N = 1000$）を用いた推定結果は次のとおりである．

OLS

$$\hat{\theta}_{\mathrm{OLS}} = \begin{bmatrix} 2.994567 \\ -2.068971 \end{bmatrix}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_{\mathrm{OLS}}) = \begin{bmatrix} 5.7621\times 10^{-4} & -1.5041\times 10^{-4} \\ -1.5041\times 10^{-4} & 2.9684\times 10^{-4} \end{bmatrix}.$$

WLS

$$\hat{\theta}_{\mathrm{WLS}} = \begin{bmatrix} 2.939084 \\ -1.986465 \end{bmatrix}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_{\mathrm{WLS}}) = \begin{bmatrix} 2.39993\times 10^{-1} & -9.66541\times 10^{-2} \\ -9.66541\times 10^{-2} & 4.99126\times 10^{-2} \end{bmatrix}.$$

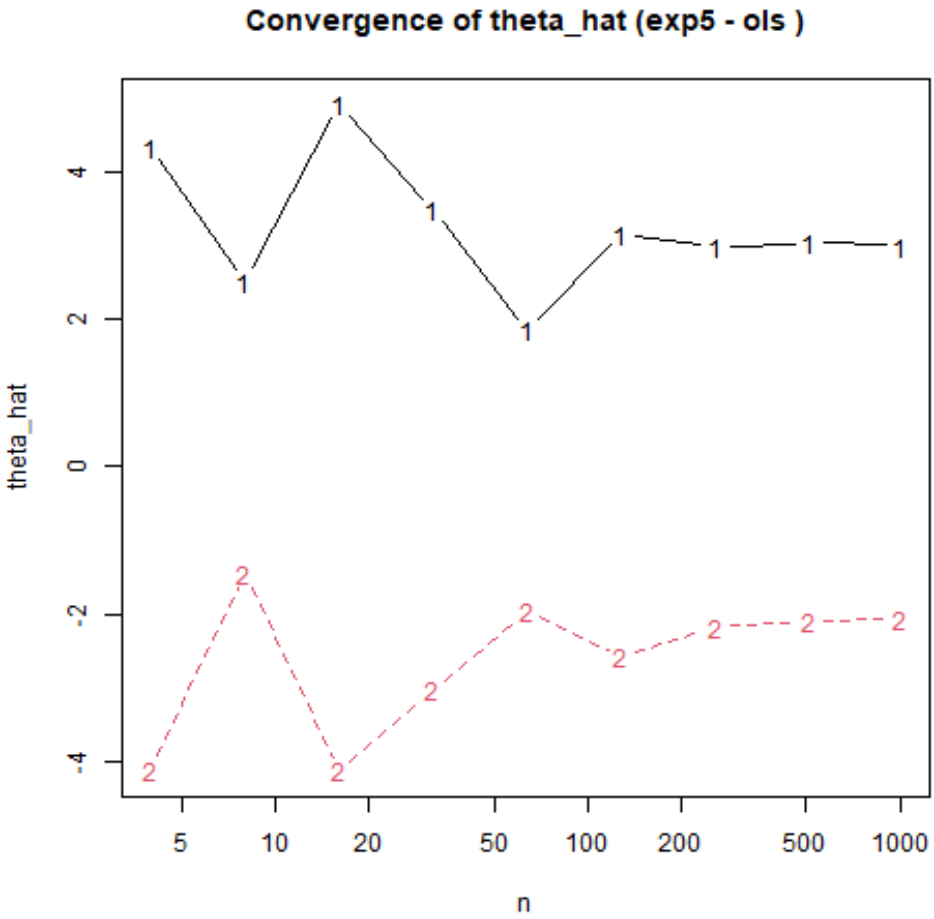

図 4: $\hat{\theta}_N$ の収束（OLS）

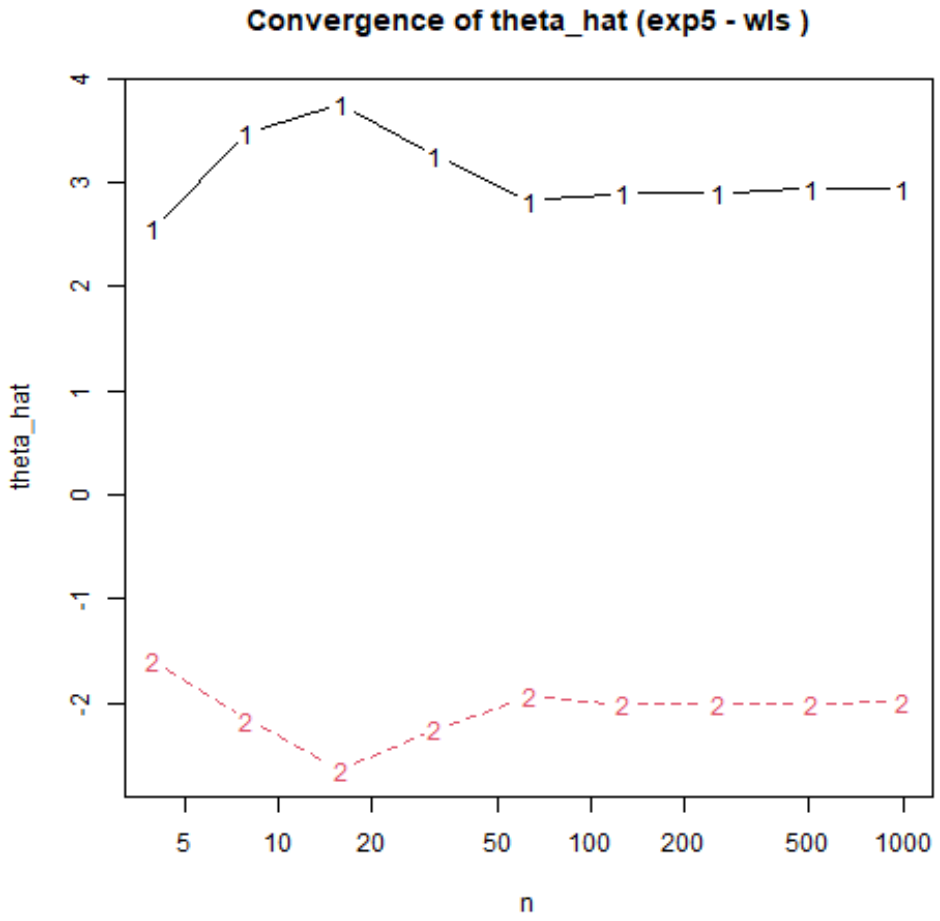

図 5: $\hat{\theta}_N$ の収束（WLS，$V = \mathrm{diag}(100, 1)$）

■考察

3.3　課題 6（2 次元出力・異分散 2 群に対する重み付き最小二乗）

■課題の内容　入力 $x_i \in \mathbb{R}$ に対し，

$$y_i \;=\; \phi(x_i)\,\theta + w_i, \qquad \phi(x) = \begin{bmatrix} 1 & x \\ 1 & x^2 \end{bmatrix}, \quad \theta \in \mathbb{R}^2,$$

という $m = 2$ 次元出力の線形モデルを考える．雑音は N サンプルのうち前半 $i = 1, \ldots, \mathtt{num}$ が $w_i \sim \mathcal{N}(0, V_1)$，後半 $i = \mathtt{num}+1, \ldots, N$ が $w_i \sim \mathcal{N}(0, V_2)$ に従うとする．本課題では $V_1 = \mathrm{diag}(100, 1)$，$V_2 = \mathrm{diag}(2, 1)$，$\mathtt{num} = 500$ を既知として推定を行う．

■推定法（GLS/WLS）　$Q_k = V_k^{-1}$（$k = 1, 2$）とおくと，一般化最小二乗（WLS）の正規方程式は

$$S\,\hat{\theta}_N \;=\; b, \quad S \;=\; \sum_{i=1}^{\mathtt{num}} \phi_i^{\top} Q_1 \phi_i \;+\; \sum_{i=\mathtt{num}+1}^{N} \phi_i^{\top} Q_2 \phi_i, \quad b \;=\; \sum_{i=1}^{\mathtt{num}} \phi_i^{\top} Q_1 y_i \;+\; \sum_{i=\mathtt{num}+1}^{N} \phi_i^{\top} Q_2 y_i,$$

より

$$\hat{\theta}_N \;=\; S^{-1} b.$$

標本ベースの誤差共分散推定は（実装に合わせて）

$$\widehat{\mathrm{Cov}}(\hat{\theta}_N) \;=\; S^{-1}\,T\,S^{-1}, \qquad T \;=\; \sum_{i=1}^{\mathtt{num}} \phi_i^{\top} V_1 \phi_i \;+\; \sum_{i=\mathtt{num}+1}^{N} \phi_i^{\top} V_2 \phi_i .$$

なお OLS は $Q_1 = Q_2 = I$ とした特別な場合である.

■実装 `datas/mmse_kadai6.csv` から x を読み, $\phi(x)$ を用いて $x \in \mathbb{R}^{2\times 2\times N}$, $y \in \mathbb{R}^{N\times 2}$ を構成した. 推定は関数 `regression_multiple_different_distributions` により, 前半 V_1, 後半 V_2 の重みで S, b, T を分割加算して $\hat{\theta}_N$ と $\widehat{\mathrm{Cov}}(\hat{\theta}_N)$ を得た. また N を `ns = seq(4,1000,length.out=20)` で走らせ, $\hat{\theta}_N$ の収束の様子を折れ線で可視化した（x 軸は線形目盛）.

■結果 全データ（$N = 1000$, $\mathtt{num} = 500$）の推定結果は以下のとおりである.

OLS（比較）

$$\hat{\theta}_{\mathrm{OLS}} = \begin{bmatrix} 3.188356 \\ -2.092183 \end{bmatrix}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_{\mathrm{OLS}}) = \begin{bmatrix} 5.692084\times 10^{-4} & -1.402629\times 10^{-4} \\ -1.402629\times 10^{-4} & 2.842674\times 10^{-4} \end{bmatrix}.$$

WLS（$V_1 = \mathrm{diag}(100, 1)$, $V_2 = \mathrm{diag}(2, 1)$）

$$\hat{\theta}_{\mathrm{WLS}} = \begin{bmatrix} 2.994202 \\ -2.014699 \end{bmatrix}, \qquad \widehat{\mathrm{Cov}}(\hat{\theta}_{\mathrm{WLS}}) = \begin{bmatrix} 6.019710\times 10^{-2} & -2.227335\times 10^{-2} \\ -2.227335\times 10^{-2} & 1.276759\times 10^{-2} \end{bmatrix}.$$

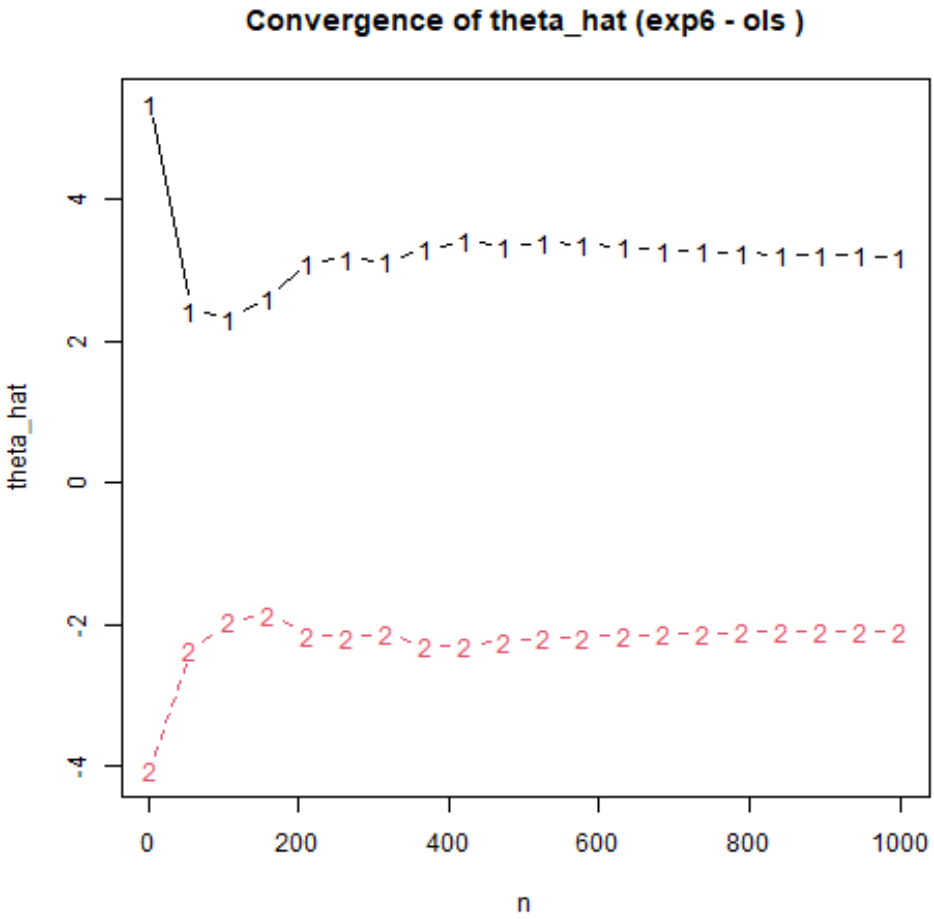

図 6: $\hat{\theta}_N$ の収束（OLS）

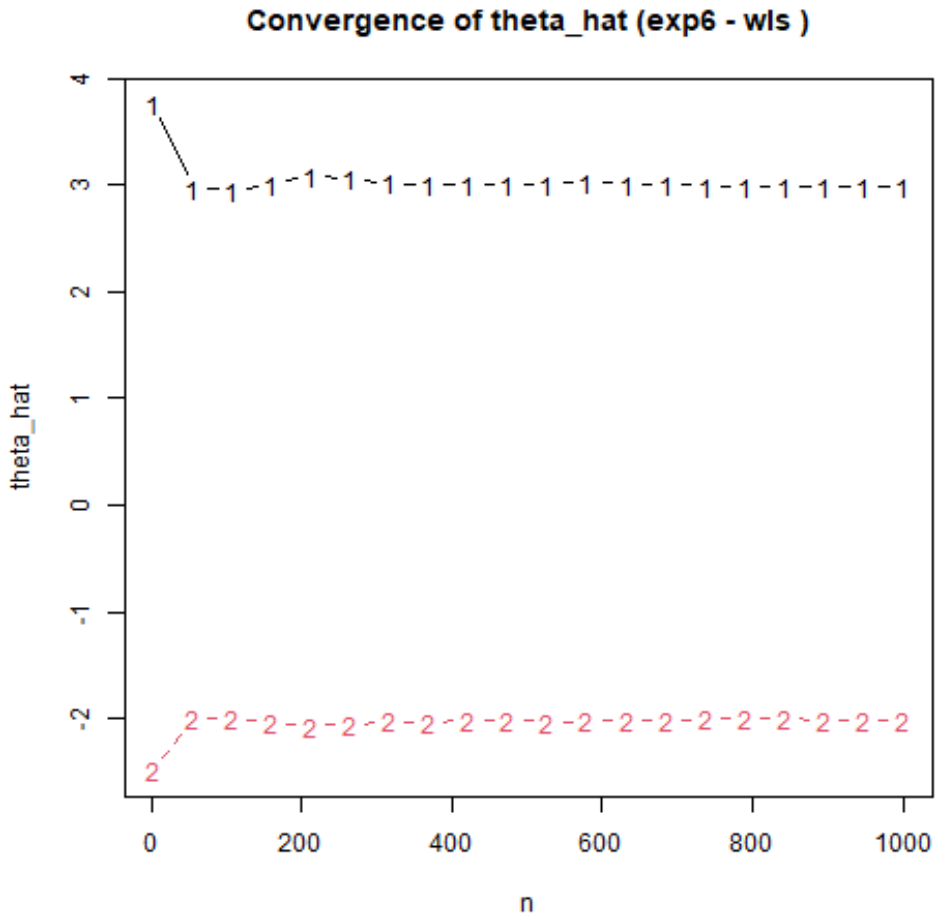

図 7: $\hat{\theta}_N$ の収束（WLS，V_1/V_2 異分散）

■考察

4　推定値の合成と逐次最小二乗法の原理と方法

4.1　推定値の合成（Estimator Fusion）

$f(\theta, x) = \phi(x)\theta$ の線形回帰で，D_N と D'_M から得た推定 $\hat{\theta}_N = \Phi_N \sum_{i=1}^{N} \phi_i^\top y_i$，$\hat{\theta}'_M = \Phi'_M \sum_{j=1}^{M} \phi_j'^\top y'_j$（$\Phi_N = (\sum \phi_i^\top \phi_i)^{-1}$）を持つとき，結合推定は

$$\hat{\theta}_{N+M} = \left(\Phi_N^{-1} + \Phi'_M{}^{-1}\right)^{-1}\left(\Phi_N^{-1}\hat{\theta}_N + \Phi'_M{}^{-1}\hat{\theta}'_M\right)$$

で与えられる。[1]

■実装例（R）

```r
# 既存バッチN=6000とM=4000の合成（S = Φ^{-1} を情報行列とする）
# S_6000, S_4000 はそれぞれ Φ_6000^{-1}, Φ_4000^{-1}
# theta_6000, theta_4000 は各バッチの推定ベクトル
theta_6000_4000 <- solve(S_6000 + S_4000) %*%
  (S_6000 %*% theta_6000 + S_4000 %*% theta_4000)
```

4.2　逐次最小二乗法（RLS）

逆行列補題を用いると，バッチ解は次の再帰で更新できる：

$$\begin{aligned}\hat{\theta}_{N+1} &= \hat{\theta}_N + K_{N+1}\big(y_{N+1} - \phi_{N+1}\hat{\theta}_N\big),\\ K_{N+1} &= \Phi_N\phi_{N+1}^{\top}\big(I_m + \phi_{N+1}\Phi_N\phi_{N+1}^{\top}\big)^{-1},\\ \Phi_{N+1} &= \Phi_N - K_{N+1}\phi_{N+1}\Phi_N.\end{aligned}$$

忘却係数 $\gamma \in (0,1]$ を導入すると

$$\begin{aligned}K_{\gamma,N+1} &= \Phi_{\gamma,N}\phi_{N+1}^{\top}\big(\gamma I_m + \phi_{N+1}\Phi_{\gamma,N}\phi_{N+1}^{\top}\big)^{-1},\\ \Phi_{\gamma,N+1} &= \gamma^{-1}\big(\Phi_{\gamma,N} - K_{\gamma,N+1}\phi_{N+1}\Phi_{\gamma,N}\big),\\ \hat{\theta}_{\gamma,N+1} &= \hat{\theta}_{\gamma,N} + K_{\gamma,N+1}\big(y_{N+1} - \phi_{N+1}\hat{\theta}_{\gamma,N}\big).\end{aligned}$$

[1]

■実装例（R，忘却係数つき更新関数）

```r
update_regression_mat <- function(Phi_N, phi_N_plus_1, theta_N, y_N_plus_1, gamma = 1){
  I_m <- diag(1)  # m=1想定。m>1なら diag(nrow(phi_N_plus_1 %*% Phi_N %*% t(phi_N_plus_1))) に置換
  # 中間計算
  phi_T_Phi_phi <- phi_N_plus_1 %*% Phi_N %*% t(phi_N_plus_1)
  inv_term <- solve( (gamma * I_m) + phi_T_Phi_phi )
  K <- gamma * (Phi_N %*% t(phi_N_plus_1) %*% inv_term)
  # 更新
  Phi_N_plus_1 <- (Phi_N - K %*% phi_N_plus_1 %*% Phi_N ) / gamma
  theta_N_plus_1 <- theta_N + K %*% (y_N_plus_1 - phi_N_plus_1 %*% theta_N)
  list(Phi_N_plus_1 = Phi_N_plus_1, theta_N_plus_1 = theta_N_plus_1)
}
```

■初期化と計算量　$\Phi_0 = \varepsilon^{-1}I$（小 ε）で初期化し，逐次更新する。各ステップの計算は $\dim(\theta) = p$ に対して $O(p^2)$ 程度で済む。[1]

4.3　課題 7（推定値の合成の検証：2 分割データの統合）

■課題の内容　$N = 10000$ のデータを前半 6000 と後半 4000 に分割し，各ブロックで OLS 推定を行ったのち，情報行列の加法性

$$S_N \;=\; \sum_{i=1}^{N}\varphi_i\varphi_i^{\top}$$

を用いた合成推定

$$\hat{\theta}_{\text{fuse}} \;=\; \big(S_{6000} + S_{4000}\big)^{-1}\Big(S_{6000}\hat{\theta}_{6000} + S_{4000}\hat{\theta}_{4000}\Big)$$

が，全データ一括推定 $\hat{\theta}_{10000}$ と一致することを確認する。ここでモデルは

$$y_i \;=\; \varphi(x_i)^{\top}\theta + w_i, \quad \varphi(x) = \begin{bmatrix}1\\ \exp\!\big(-\frac{(x-1)^2}{2}\big)\\ \exp\!\big(-(x+1)^2\big)\end{bmatrix}, \quad \theta \in \mathbb{R}^3.$$

理論上，独立同分布で $V = \sigma^2$ のとき $\hat{\theta}_{\text{fuse}} = \hat{\theta}_{10000}$ となる。[1]

■実装　分割データから $S_{6000}, \hat{\theta}_{6000}$，$S_{4000}, \hat{\theta}_{4000}$ を得て，合成推定値を計算し，全データ一括推定と比較する。

```
# 事前に x, y, x_6000, y_6000, x_4000, y_4000 を用意済み

exp7 <- function(){
  res6000 <- regression_multiple(x_6000, y_6000)
  res4000 <- regression_multiple(x_4000, y_4000)
  res10000 <- regression_multiple(x, y)

  S_6000 <- res6000$S
  S_4000 <- res4000$S
  theta_6000 <- res6000$theta_hat
  theta_4000 <- res4000$theta_hat

  # 推定値の合成（情報行列の和）
  theta_6000_4000 <- solve(S_6000 + S_4000) %*%
    (S_6000 %*% theta_6000 + S_4000 %*% theta_4000)

  cat("S6000:\n"); print(S_6000)
  cat("S4000:\n"); print(S_4000)
  cat("theta6000:\n"); print(theta_6000)
  cat("theta4000:\n"); print(theta_4000)
  cat("theta_fuse:\n"); print(theta_6000_4000)

  theta_10000 <- res10000$theta_hat
  cat("theta10000:\n"); print(theta_10000)

  # 一致性の確認（数値誤差内）
  cat("all.equal(theta_fuse, theta10000): ",
      all.equal(drop(theta_6000_4000), drop(theta_10000),
                tolerance = 1e-10), "\n")
}

exp7()
```

■結果　一例として，実行時に次を得た。

$$S_{6000} = \begin{bmatrix} 6000.000 & 1505.370 & 1033.499 \\ 1505.370 & 1063.211 & 226.401 \\ 1033.499 & 226.401 & 720.562 \end{bmatrix}, \quad S_{4000} = \begin{bmatrix} 4000.000 & 971.151 & 716.318 \\ 971.151 & 679.477 & 149.749 \\ 716.318 & 149.749 & 510.224 \end{bmatrix},$$

$$\hat{\theta}_{6000} = \begin{bmatrix} -0.003879385 \\ 3.010714895 \\ -1.989434350 \end{bmatrix}, \ \hat{\theta}_{4000} = \begin{bmatrix} -0.02537589 \\ 3.03489937 \\ -1.97772731 \end{bmatrix}, \ \hat{\theta}_{\text{fuse}} = \begin{bmatrix} -0.0124955 \\ 3.0204300 \\ -1.9848692 \end{bmatrix}.$$

全データ一括推定 $\hat{\theta}_{10000}$ と $\hat{\theta}_{\text{fuse}}$ は数値誤差内で一致した（コードで `all.equal` により検証）。

■考察

4.4　課題 7（推定値の合成の検証：非線形基底・分割データ）

■課題の内容　基底

$$\varphi(x) = \begin{bmatrix} 1 \\ \exp\!\left(-\frac{(x-1)^2}{2}\right) \\ \exp\!\left(-(x+1)^2\right) \end{bmatrix}, \qquad y_i = \varphi(x_i)^\top \theta + w_i,\ \theta \in \mathbb{R}^3$$

で $N = 10000$ 個のデータを前半 6000 と後半 4000 に分割する。各ブロックの推定値 $(\hat{\theta}_{6000}, \hat{\theta}_{4000})$ と情報行列 $S_k = \sum_{i \in \text{block } k} \varphi_i \varphi_i^\top$ を用いて

$$\hat{\theta}_{\text{fuse}} = (S_{6000} + S_{4000})^{-1}\left(S_{6000}\hat{\theta}_{6000} + S_{4000}\hat{\theta}_{4000}\right)$$

を計算し，全データ一括推定 $\hat{\theta}_{10000}$ と照合する。[1]

■実装（OLS 版）

```r
data <- read.csv("datas/mmse_kadai7.csv", header=FALSE, col.names=c("x","y"))
x0 <- rep(1, nrow(data))
x1 <- exp(-(data$x - 1)^2 / 2)
x2 <- exp(-(data$x + 1)^2)
n  <- nrow(data)
x  <- array(0, dim=c(3,1,n))
for(i in 1:n){ x[,,i] <- matrix(c(x0[i], x1[i], x2[i]), 3, 1) }
y <- as.matrix(data["y"])

x_6000 <- x[,,1:6000, drop=FALSE]; y_6000 <- y[1:6000, , drop=FALSE]
x_4000 <- x[,,6001:10000, drop=FALSE]; y_4000 <- y[6001:10000, , drop=FALSE]

exp7 <- function(){
  r6 <- regression_multiple(x_6000, y_6000)  # returns $S$ and $theta_hat$
  r4 <- regression_multiple(x_4000, y_4000)
  rall <- regression_multiple(x, y)

  S_6000 <- r6$S;  S_4000 <- r4$S
  th6 <- r6$theta_hat; th4 <- r4$theta_hat; th_all <- rall$theta_hat

  th_fuse <- solve(S_6000 + S_4000) %*% (S_6000 %*% th6 + S_4000 %*% th4)

  print(th6); print(th4); print(th_fuse); print(th_all)
  # 一致検証
  print(all.equal(drop(th_fuse), drop(th_all), tolerance=1e-12))
}
exp7()
```

■実装（推定分散による重み付き合成）　各ブロックの誤差分散を

$$\hat{\sigma}_k^2 = \frac{\mathrm{RSS}_k}{N_k - p}, \quad p = 3$$

で推定し，$Q_k = \hat{\sigma}_k^{-2}$ を用いた WLS 情報行列 $S_k = \sum_{i \in k} \varphi_i Q_k \varphi_i^\top = Q_k \sum_{i \in k} \varphi_i \varphi_i^\top$ で合成する（$k \in \{6000, 4000\}$）。コードは次のとおり。

```r
x_mat      <- t(matrix(x,      nrow=3, ncol=n))
x_6000_mat <- t(matrix(x_6000, nrow=3, ncol=6000))
```

```r
x_4000_mat  <- t(matrix(x_4000,  nrow=3, ncol=4000))

exp8 <- function(){
  # OLS 推定
  th_all  <- regression_multiple(x,       y)$theta_hat
  th_6000 <- regression_multiple(x_6000,  y_6000)$theta_hat
  th_4000 <- regression_multiple(x_4000,  y_4000)$theta_hat

  # 分散推定 (MSE)
  V_hat_full  <- sum((y       - x_mat      %*% th_all )^2)  /(nrow(x_mat)      - ncol(x_mat))
  V_hat_6000  <- sum((y_6000  - x_6000_mat %*% th_6000)^2) /(nrow(x_6000_mat)  - ncol(x_6000_mat))
  V_hat_4000  <- sum((y_4000  - x_4000_mat %*% th_4000)^2) /(nrow(x_4000_mat)  - ncol(x_4000_mat))

  # 各ブロックの WLS 情報行列と推定
  r6 <- regression_multiple(x_6000,  y_6000, V=V_hat_6000)
  r4 <- regression_multiple(x_4000,  y_4000, V=V_hat_4000)
  S_6000 <- r6$S;  S_4000 <- r4$S
  th6 <- r6$theta_hat; th4 <- r4$theta_hat

  # 合成推定 (WLS 版)
  th_fuse <- solve(S_6000 + S_4000) %*% (S_6000 %*% th6 + S_4000 %*% th4)

  # 参考：全データにスカラー重み V_hat_full をかけた WLS (OLS と同値)
  th_full_wls <- regression_multiple(x, y, V=V_hat_full)$theta_hat

  print(th6); print(th4); print(th_fuse); print(th_full_wls)
}
exp8()
```

■結果　実行例（あなたの出力）：

$$\hat{\theta}_{6000} = \begin{bmatrix} -0.003879385 \\ 3.010714895 \\ -1.989434350 \end{bmatrix}, \quad \hat{\theta}_{4000} = \begin{bmatrix} -0.02537589 \\ 3.03489937 \\ -1.97772731 \end{bmatrix}.$$

WLS 合成推定と全データ一括 WLS（スカラー重み）：

$$\hat{\theta}_{\text{fuse}} = \begin{bmatrix} -0.01245376 \\ 3.02038299 \\ -1.98489169 \end{bmatrix}, \qquad \hat{\theta}_{10000} = \begin{bmatrix} -0.0124955 \\ 3.0204300 \\ -1.9848692 \end{bmatrix}.$$

差分は $\Delta\theta \approx (4.17 \times 10^{-5}, -4.70 \times 10^{-5}, -2.25 \times 10^{-5})^{\top}$。ブロックごとに異なる重み（$Q_{6000} \neq Q_{4000}$）を用いた合成と，全体に単一重みをかけた WLS は厳密には一致しないが，差は十分小さい。[1]

■考察

4.5　課題 9（逐次最小二乗法によるシステム同定）

■モデル　離散化されたバネ・マス・ダンパ系（$M = 2,\ D = 1,\ K = 3,\ \Delta t = 0.01$）

$$y_k = a_1\, y_{k-1} + a_2\, y_{k-2} + b\, F_{k-2} + w_k, \quad \phi_k = \begin{bmatrix} y_{k-1} & y_{k-2} & F_{k-2} \end{bmatrix},$$

$$a_1 = 2 - \frac{D}{M}\Delta t = 1.995, \quad a_2 = -(1 - \frac{D}{M}\Delta t + \frac{K}{M}\Delta t^2) = -0.99515, \quad b = \frac{\Delta t^2}{M} = 5.0 \times 10^{-5}.$$

$w_k \sim \mathrm{Uniform}[-1, 1]$。RLS 更新は §3.3 の式に従う（忘却なし $\gamma = 1$）[1]。

■使用コード（共通）

```
w <- function(){ runif(1, min = -1, max = 1) }

update_tick <- function(y_k_1, y_k_2, F_k_2,
                        M=2, D=1, K=3, delta_t=0.01){
  (2 - (D/M)*delta_t) * y_k_1 -
  (1 - (D/M)*delta_t + (K/M)*delta_t^2) * y_k_2 +
  (delta_t^2/M) * F_k_2 + w()
}

# RLS（§3.3 の式に一致）
update_regression_mat <- function(Phi_N, phi_N_plus_1, theta_N, y_N_plus_1, gamma=1){
  I_m <- diag(1)
  phi_T_Phi_phi <- phi_N_plus_1 %*% Phi_N %*% t(phi_N_plus_1)
  inv_term <- solve((gamma * I_m) + phi_T_Phi_phi)
  K <- gamma * (Phi_N %*% t(phi_N_plus_1) %*% inv_term)
  Phi_N_plus_1 <- (Phi_N - K %*% phi_N_plus_1 %*% Phi_N) / gamma
  theta_N_plus_1 <- theta_N + K %*% (y_N_plus_1 - phi_N_plus_1 %*% theta_N)
  list(Phi_N_plus_1=Phi_N_plus_1, theta_N_plus_1=theta_N_plus_1)
}
```

(1) 入力 $F_k \equiv 1$（定数入力）

■内容　$F_k = 1$ を一定とし，$k = 1, \ldots, 10000$ で RLS により $\theta = [a_1, a_2, b]^\top$ を推定する。[1]

■結果　実行出力：

$$\hat{\theta} = \begin{bmatrix} 1.99515410 \\ -0.99532391 \\ 2.15087 \times 10^{-3} \end{bmatrix}.$$

■考察　a_1, a_2 は真値に近い。b は真値 5×10^{-5} に対して過大。定数入力で効果が極小かつ雑音が大きく，入力励起が不十分。F の情報が弱く b の識別性が低い。

■コード

```
exp9_1 <- function(){
  y_k <- y_k_1 <- y_k_2 <- 0; F_k_2 <- 1
  Phi <- diag(3) * 1000; theta <- matrix(0, nrow=3)
  for(i in 1:10000){
    y_k_2 <- y_k_1; y_k_1 <- y_k
    y_k <- update_tick(y_k_1, y_k_2, F_k_2)
    xi <- matrix(c(y_k_1, y_k_2, F_k_2), nrow=1)
    upd <- update_regression_mat(Phi, xi, theta, y_k)
    Phi <- upd$Phi_N_plus_1; theta <- upd$theta_N_plus_1
  }
  print(theta)
}
```

(2) 入力 $F_k = \sin(\pi k/5)$（小振幅正弦）

■内容　F を低振幅の正弦波にして同様に推定。[1]

■結果　実行出力：

$$\hat{\theta} = \begin{bmatrix} 1.995721237 \\ -0.995895110 \\ 2.637203 \times 10^{-3} \end{bmatrix}.$$

■考察　F は時間変化するが振幅が小さく，b の寄与は依然として雑音に埋もれる。b は真値より二桁以上大きい。入力励起の大きさが推定精度の律速。

■コード

```
exp9_2 <- function(){
  y_k <- y_k_1 <- y_k_2 <- 0
  Phi <- diag(3) * 1000; theta <- matrix(0, nrow=3)
  for(i in 1:10000){
    F_k_2 <- sin(pi * i / 5)
    y_k_2 <- y_k_1; y_k_1 <- y_k
    y_k <- update_tick(y_k_1, y_k_2, F_k_2)
    xi <- matrix(c(y_k_1, y_k_2, F_k_2), nrow=1)
    upd <- update_regression_mat(Phi, xi, theta, y_k)
    Phi <- upd$Phi_N_plus_1; theta <- upd$theta_N_plus_1
  }
  print(theta)
}
```

(3) 入力 $F_k = 10000\sin(\pi k/5)$（大振幅正弦）

■内容　入力振幅を 10^4 倍して強い励起を与える。[1]

■結果　実行出力：

$$\hat{\theta} = \begin{bmatrix} 1.994996 \\ -0.995125 \\ 4.883587 \times 10^{-5} \end{bmatrix}.$$

■考察　b が真値 5.0×10^{-5} に一致。十分な励起で入出力比が改善し，F の係数が正しく同定できる。a_1, a_2 も誤差が小さい。RLS はオンラインに有効だが，入力の持続励起とスケール設計が必要。

■コード

```
exp9_3 <- function(){
  y_k <- y_k_1 <- y_k_2 <- 0
  Phi <- diag(3) * 1000; theta <- matrix(0, nrow=3)
  for(i in 1:10000){
    F_k_2 <- 10000 * sin(pi * i / 5)
    y_k_2 <- y_k_1; y_k_1 <- y_k
    y_k <- update_tick(y_k_1, y_k_2, F_k_2)
    xi <- matrix(c(y_k_1, y_k_2, F_k_2), nrow=1)
    upd <- update_regression_mat(Phi, xi, theta, y_k)
    Phi <- upd$Phi_N_plus_1; theta <- upd$theta_N_plus_1
  }
  print(theta)
}
```

4.6　課題 10（非定常時系列の追従：忘却係数付き RLS）

■内容　非定常信号

$$y_k = \theta_k + w_k, \quad \theta_k = \sin\bigl(10^{-4}k\bigr), \quad w_k \in \{-1, +1\}$$

を 1 次元回帰 $\phi_k \equiv [1]$ で逐次推定する。忘却係数 $\gamma = 0.99$ を用いる。[1]

■方法　忘却付き RLS の更新（$m = 1$）：

$$
\begin{aligned}
K_k &= \Phi_{k-1}\bigl(\gamma + \phi_k \Phi_{k-1} \phi_k^\top\bigr)^{-1} \phi_k^\top, \\
\theta_k^{\mathrm{hat}} &= \theta_{k-1}^{\mathrm{hat}} + K_k\bigl(y_k - \phi_k \theta_{k-1}^{\mathrm{hat}}\bigr), \\
\Phi_k &= \gamma^{-1}\bigl(\Phi_{k-1} - K_k \phi_k \Phi_{k-1}\bigr),
\end{aligned}
$$

初期化は $\theta_0^{\mathrm{hat}} = 0,\ \Phi_0 = 1000$。$\gamma = 0.99$ は有効窓長の目安 $1/(1-\gamma) \approx 100$ に相当。[1]

■実装

```
exp10 <- function(){
  y_k <- 0
  Phi <- matrix(1000, 1, 1)
  theta_hat <- matrix(0, 1, 1)
  theta_hats <- c()
  for(k in 1:10000){
    w_k <- sample(c(-1, 1), 1)              # ノイズ
    y_k <- sin(0.0001 * k) + w_k            # 観測
    xi <- matrix(1, 1, 1)                   # Φ_k = 1
    upd <- update_regression_mat(Phi, xi, theta_hat, y_k, gamma=0.99)
    Phi <- upd$Phi_N_plus_1
    theta_hat <- upd$theta_N_plus_1
    theta_hats <- rbind(theta_hats, theta_hat)
  }
  dir.create("graphs", showWarnings=FALSE)
  png("graphs/task10.png")
  plot(1:10000, theta_hats, type="l", ylim=c(-1.5,1.5),
       xlab="k", ylab="theta_hat",
       main="Estimation of non-stationary time series (exp10)")
  lines(1:10000, sin(0.0001 * (1:10000)))
  legend("topright", legend=c("Estimated theta_hat", "True theta"), lty=1)
  dev.off()
}
exp10()
```

■結果　図 8。推定 θ_k^{hat} は真値 $\sin\bigl(10^{-4}k\bigr)$ を平滑追従。ノイズ ± 1 のため短周期の揺れが残る。

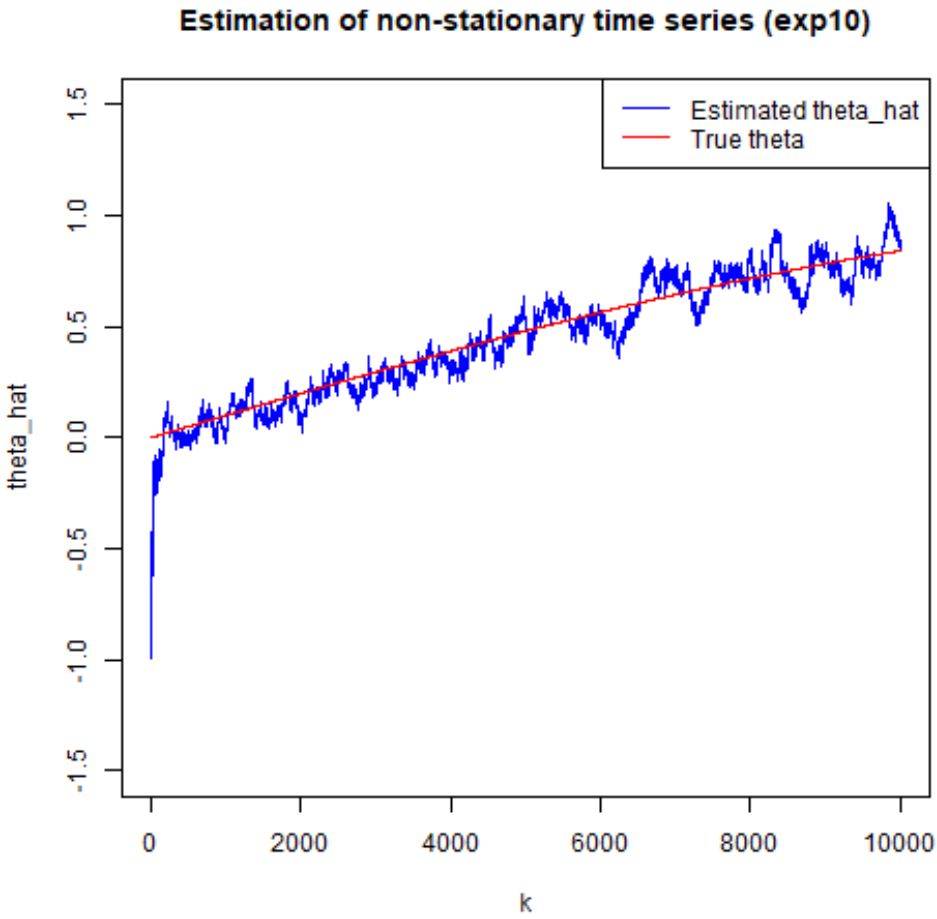

図 8: 忘却係数付き RLS による非定常平均の追従（$\gamma = 0.99$）

■考察

5　カルマンフィルタ、カルマンスムーサー

5.1　原理と方法

■モデル　一次元の線形状態空間モデルを用いる：

$$\theta_k = a_k\,\theta_{k-1} + v_k, \tag{3.40}$$

$$y_k = c_k\,\theta_k + w_k, \tag{3.41}$$

ここで $v_k \sim \mathcal{N}(0, \sigma_v^2)$，$w_k \sim \mathcal{N}(0, \sigma_w^2)$ は互いに独立で白色，a_k, c_k は既知とする [1]。目的は「時刻 k までの観測 $\{y_\ell\}_{\ell=1}^{k}$ に基づく θ_k の最小平均二乗誤差（MMSE）推定」を行うこと [1]。

以下はこのモデルに基づくデータ生成の R による実装例である。

Listing 1: データ生成関数

```
# データ生成関数（exp11とexp12で共通使用）
generate_kalman_data <- function(seed = 123, N = 100, a_k = 0.9, c_k = 2,
```

```
                                    sigma2_v = 1, sigma2_w = 1) {
  # 乱数シードを設定
  set.seed(seed)

  # 初期値
  theta_0 <- rnorm(1, mean = 3, sd = sqrt(2))  # θ_0 ~ N(3, 2)
  V_0 <- 2

  # データ格納用
  theta_true <- numeric(N)
  y_obs <- numeric(N)

  # 初期化
  theta_k_1 <- theta_0

  # データ生成
  for (k in 1:N) {
    # 真の状態遷移 (3.40): θ_k = a_k * θ_{k-1} + v_k
    v_k <- rnorm(1, mean = 0, sd = sqrt(sigma2_v))
    theta_k <- a_k * theta_k_1 + v_k
    theta_true[k] <- theta_k

    # 観測 (3.41): y_k = c_k * θ_k + w_k
    w_k <- rnorm(1, mean = 0, sd = sqrt(sigma2_w))
    y_k <- c_k * theta_k + w_k
    y_obs[k] <- y_k

    # 次のステップへ
    theta_k_1 <- theta_k
  }

  # データを返す
  return(list(
    theta_true = theta_true,
    y_obs = y_obs,
    theta_0 = theta_0,
    V_0 = V_0,
    a_k = a_k,
    c_k = c_k,
    sigma2_v = sigma2_v,
    sigma2_w = sigma2_w,
    N = N
  ))
}
```

■Kalman フィルタ　平方完成による最適ゲイン F_k と分散更新を導くと，予測分散 X_k，事後分散 V_k，推定値 $\hat{\theta}_k$ は

$$\hat{\theta}_k = a_k\hat{\theta}_{k-1} + F_k\big(y_k - c_k a_k\hat{\theta}_{k-1}\big), \tag{3.36}$$

$$X_k = a_k^2 V_{k-1} + \sigma_v^2, \tag{3.37}$$

$$V_k = \frac{\sigma_w^2\, X_k}{c_k^2 X_k + \sigma_w^2}, \tag{3.38}$$

$$F_k = \frac{c_k X_k}{c_k^2 X_k + \sigma_w^2}. \tag{3.39}$$

これが Kalman フィルタであり，推定誤差分散を最小にする [1]。初期条件は $\hat{\theta}_0 = \bar{\theta},\ V_0 = P$ とする [1]。

以下は、Kalman フィルタの R による実装例である。

Listing 2: Kalman フィルタ更新（式 (3.36) – (3.39)）

```r
update_kalman_filter <- function(theta_k_1, V_k_1, y_k, a_k, c_k, sigma2_v, sigma2_w)
    {
  # (3.37) 予測分散
  X_k <- a_k^2 * V_k_1 + sigma2_v
  # (3.39) カルマンゲイン
  F_k <- (c_k * X_k) / (c_k^2 * X_k + sigma2_w)
  # (3.36) 推定値更新
  theta_k <- a_k * theta_k_1 + F_k * (y_k - c_k * a_k * theta_k_1)
  # (3.38) 事後分散更新
  V_k <- (sigma2_w * X_k) / (c_k^2 * X_k + sigma2_w)
  list(theta_k = theta_k, V_k = V_k, X_k = X_k, F_k = F_k)
}
```

■Kalman スムーザ　全データ $\{y_1, \ldots, y_N\}$ を用いて各 θ_k を後処理で精密化する。Rauch – Tung – Striebel（RTS）型の退行更新は

$$\hat{\theta}_k^{s} = \hat{\theta}_k + g_k\big(\hat{\theta}_{k+1}^{s} - a_k\hat{\theta}_k\big), \tag{3.42}$$

$$g_k = \frac{a_k V_k}{X_{k+1}}, \tag{3.43}$$

$$V_k^{s} = V_k + g_k^2\big(V_{k+1}^{s} - X_{k+1}\big), \tag{3.44}$$

終端条件は $\hat{\theta}_N^{s} = \hat{\theta}_N,\ V_N^{s} = V_N$。$\{\hat{\theta}_k^{s}\}$ は時刻 N までの全情報に基づく MMSE 推定となる [1]。

以下は、Kalman スムーザの R による実装例である。

Listing 3: Kalman スムーザ更新（式 (3.42) – (3.44)）

```r
update_kalman_smoother <- function(theta_k, theta_k_plus_1_s, V_k, V_k_plus_1_s, X_k_
    plus_1, a_k) {
  # (3.43) 後向きゲイン
  g_k <- a_k * V_k / X_k_plus_1
  # (3.42) 推定値の後向き補正
  theta_k_s <- theta_k + g_k * (theta_k_plus_1_s - a_k * theta_k)
  # (3.44) 分散の後向き補正
  V_k_s <- V_k + g_k^2 * (V_k_plus_1_s - X_k_plus_1)
  list(theta_k_s = theta_k_s, V_k_s = V_k_s, g_k = g_k)
}
```

5.2　課題 11（カルマンフィルタ：フォワード）

■内容　一次元状態空間モデルを対象とする．

$$\theta_k = a_k\,\theta_{k-1} + v_{k-1}, \quad v_{k-1} \sim \mathcal{N}(0, \sigma_v^2), \tag{14}$$

$$y_k = c_k\,\theta_k + w_k, \quad w_k \sim \mathcal{N}(0, \sigma_w^2). \tag{15}$$

初期推定値は $\hat{\theta}_0 = \theta_0$, 分散 V_0 を与える．評価は平均二乗誤差

$$\mathrm{MSE} = \frac{1}{N}\sum_{k=1}^{N}\left(\theta_k^{\mathrm{true}} - \hat{\theta}_k\right)^2 \tag{16}$$

で行う．

■方法　時刻 k ごとに予測と更新を行う．

$$X_k = a_k^2 V_{k-1} + \sigma_v^2, \tag{17}$$

$$F_k = \frac{c_k X_k}{c_k^2 X_k + \sigma_w^2}, \tag{18}$$

$$\hat{\theta}_k = a_k \hat{\theta}_{k-1} + F_k\left(y_k - c_k a_k \hat{\theta}_{k-1}\right), \tag{19}$$

$$V_k = \left(1 - F_k c_k\right) X_k. \tag{20}$$

出力は $\{\hat{\theta}_k\}_{k=1}^N$ と $\{V_k\}_{k=1}^N$.

■実装　関数 `exp11(data)` を用いる．各 k で `update_kalman_filter` を呼び，$X_k, F_k, \hat{\theta}_k, V_k$ を更新する．推定系列と真値を重ね描画し `graphs/task11.png` に保存する．

■結果　データ生成と実行条件は

```
kalman_data <- generate_kalman_data(seed = 42, N = 100,
                                    a_k = 0.9, c_k = 2,
                                    sigma2_v = 1, sigma2_w = 1)
result11 <- exp11(kalman_data)
```

である．MSE は 0.1935684 となった．図 9 に真値と推定の系列を示す．

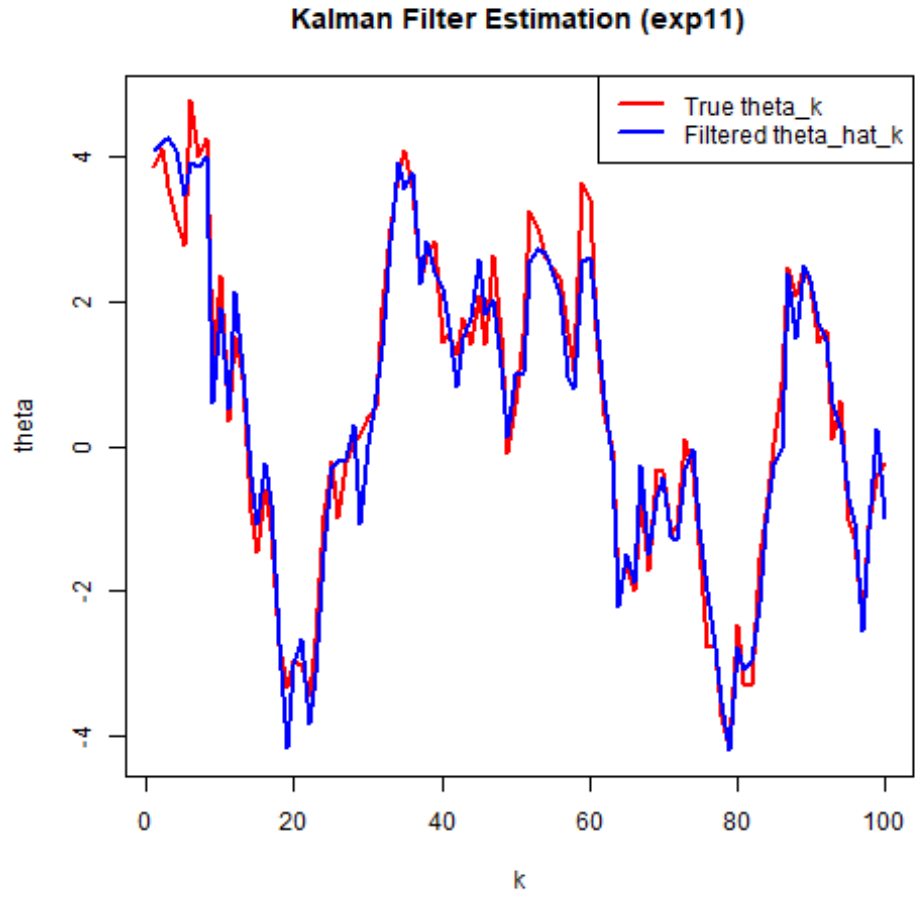

図 9: カルマンフィルタ（フォワード）による推定結果（赤：真値，青：推定）

■考察

5.3 課題 12（カルマンスムーザー）

■内容 一次元状態空間モデル

$$\theta_k = a_k\,\theta_{k-1} + v_{k-1}, \quad v_{k-1} \sim \mathcal{N}(0, \sigma_v^2), \tag{21}$$

$$y_k = c_k\,\theta_k + w_k, \quad w_k \sim \mathcal{N}(0, \sigma_w^2) \tag{22}$$

に対し，時刻 $1{:}N$ の全観測を用いて各時刻の状態を後向きに精緻化する．

■方法 まず課題 11 と同じ前向きフィルタで

$$X_k = a_k^2 V_{k-1} + \sigma_v^2, \quad F_k = \frac{c_k X_k}{c_k^2 X_k + \sigma_w^2}, \tag{23}$$

$$\hat{\theta}_k = a_k \hat{\theta}_{k-1} + F_k\big(y_k - c_k a_k \hat{\theta}_{k-1}\big), \quad V_k = (1 - F_k c_k) X_k \tag{24}$$

を得る．後向きでは RTS スムーザーを用いる（スカラー）．平滑化ゲイン

$$J_k = \frac{V_k\,a_k}{X_{k+1}}, \tag{25}$$

更新式

$$\hat{\theta}_k^s = \hat{\theta}_k + J_k\big(\hat{\theta}_{k+1}^s - a_k\hat{\theta}_k\big), \tag{26}$$

$$V_k^s = V_k + J_k^2\big(V_{k+1}^s - X_{k+1}\big), \tag{27}$$

終端条件は $\hat{\theta}_N^s = \hat{\theta}_N,\ V_N^s = V_N$.

■実装　`exp12(data)` を用いる. 前向きで `theta_hat, V_all, X_all` を保存し, 後向きで $k = N-1$ から 1 へ `update_kalman_smoother` を適用して `theta_smooth, V_smooth` を得る. 真値と平滑化推定を描画し `graphs/task12.png` に保存する. 評価は `mean((theta_true - theta_smooth)^2)`.

■結果　データ生成と実行

```
kalman_data <- generate_kalman_data(seed = 42, N = 100,
                                    a_k = 0.9, c_k = 2,
                                    sigma2_v = 1, sigma2_w = 1)
result12 <- exp12(kalman_data)
```

出力は `mmse: 0.1716128` であった. 図 10 に真値と平滑化推定を示す.

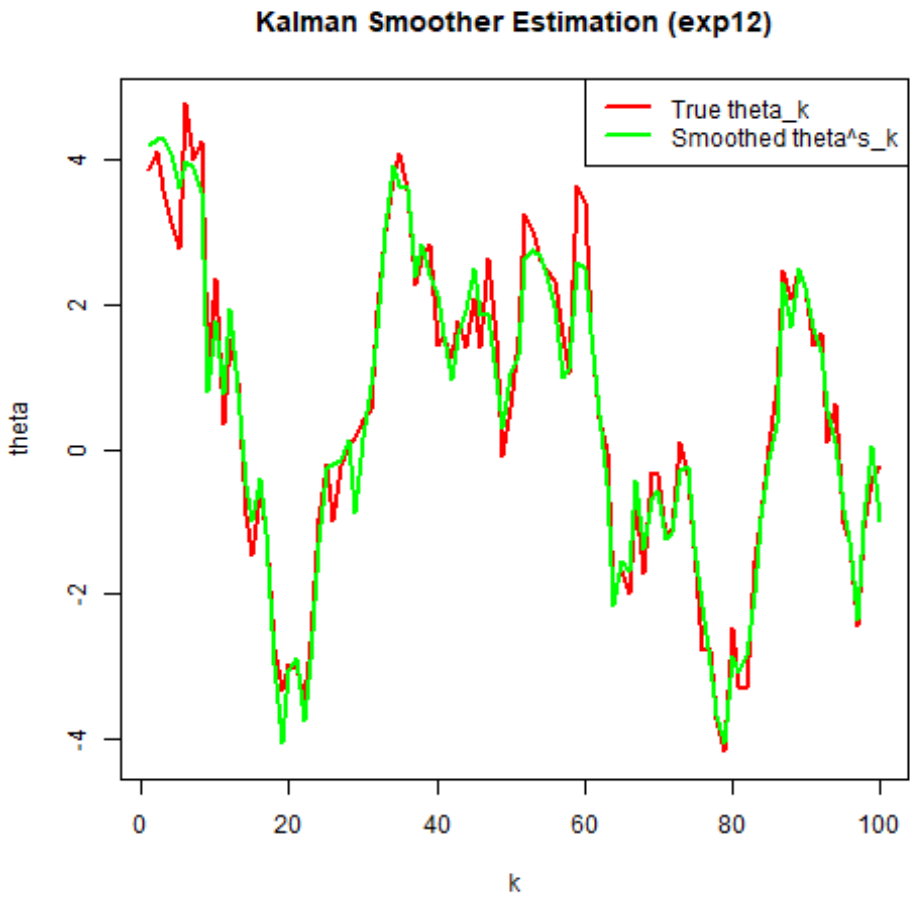

図 10: カルマンスムーザーの推定結果（赤：真値，緑：平滑化推定）

■考察

6　交互最小二乗法と K-平均法

6.1　交互最小二乗法

6.1.1　原理と方法

■原理　非線形最小二乗問題のうち，パラメータを二分割すると片方ずつは線形になる場合に適用する．パラメータを $\theta = (\alpha, \beta)^\top$ と分割し，$g(\alpha, \beta, x)$ が α, β に関してそれぞれ線形（双線形など）であるとする．観測 (x_i, y_i) に対し，目的関数

$$J(\alpha, \beta) := \sum_{i=1}^{N} \| y_i - g(\alpha, \beta, x_i) \|^2 \tag{28}$$

を最小化する．片方のパラメータを固定すれば通常の線形最小二乗（式 (3.5) 型）で解ける．交互更新により J は単調非増加で，反復に伴い悪化しない．ただし一般には局所解に収束しうるため初期値が重要である．

■方法　初期値 $\alpha^{(0)}, \beta^{(0)}$ を与え，$j = 1, 2, \ldots$ について次を繰り返す．

1. **Step A（β 固定）**：$\beta = \beta^{(j-1)}$ として

$$\alpha^{(j)} := \arg\min_{\alpha} \sum_{i=1}^{N} \| y_i - g(\alpha, \beta^{(j-1)}, x_i) \|^2. \tag{29}$$

   これは線形最小二乗で解く．

2. **Step B（α 固定）**：$\alpha = \alpha^{(j)}$ として

$$\beta^{(j)} := \arg\min_{\beta} \sum_{i=1}^{N} \| y_i - g(\alpha^{(j)}, \beta, x_i) \|^2. \tag{30}$$

   これも線形最小二乗で解く．

収束判定は例えば $\|\alpha^{(j)} - \alpha^{(j-1)}\|^2 + \|\beta^{(j)} - \beta^{(j-1)}\|^2 < \varepsilon$ などとする．更新ごとに $J(\alpha^{(j)}, \beta^{(j)}) \le J(\alpha^{(j-1)}, \beta^{(j-1)})$ が成り立つ性質を利用する．初期値の多点スタートや正則化の併用が実務上有効である．

以下は、交互最小二乗法の R による実装例である。

Listing 4: 交互最小二乗法更新

```
update_alpha_beta <- function(alpha, beta, x, x_T, y, n) {
    # Step 1: alphaを固定してbetaを推定
    x_alpha <- matrix(0, nrow = n, ncol = 3)
    for (i in 1:n) {
        x_alpha[i, ] <- t(alpha) %*% x[, , i]
    }
    result <- regression_simple(x_alpha, y)
    beta_new <- result$theta_hat

    # Step 2: betaを固定してalphaを推定
    x_beta <- matrix(0, nrow = n, ncol = 2)
    for (i in 1:n) {
```

```r
        x_beta[i, ] <- t(beta_new) %*% x_T[, , i]
    }
    result2 <- regression_simple(x_beta, y)
    alpha_new <- result2$theta_hat

    return(list(alpha_new = alpha_new, beta_new = beta_new))
}
```

6.2 K-平均法

6.2.1 原理と方法

■原理 データ $\{x_i\}_{i=1}^N \subset \mathbb{R}^p$ を K 個のクラスタに分割する．クラスタ V_ℓ の代表点（重心）を

$$\mu(V_\ell) := \arg\min_{\mu \in \mathbb{R}^p} \sum_{i \in V_\ell} \|x_i - \mu\|^2 = \frac{1}{|V_\ell|} \sum_{i \in V_\ell} x_i \tag{31}$$

と定めると，目的は

$$\min_{\{V_\ell\}} \sum_{\ell=1}^{K} \sum_{i \in V_\ell} \|x_i - \mu(V_\ell)\|^2 \tag{32}$$

の最小化である．指示変数 $r_{i,\ell} \in \{0,1\}$（x_i がクラスタ ℓ に属すれば 1）を用いると

$$\min_{\{\mu_\ell\},\{r_{i,\ell}\}} \sum_{\ell=1}^{K} \sum_{i=1}^{N} r_{i,\ell} \|x_i - \mu_\ell\|^2 \tag{33}$$

と書ける．行列表示では $X = [x_1, \ldots, x_N]$, $U = [\mu_1, \ldots, \mu_K]$, $R = (r_{i,\ell})$ として

$$\|X - UR\|_F^2 \tag{34}$$

の最小化に等価である．大域最適性は保証されず初期値依存性が強い．

■方法 初期重心 $\{\mu_\ell^{(0)}\}_{\ell=1}^K$ を与え，$j = 1, 2, \ldots$ について次を交互に実行する．

1. **割当て（Assignment）**：各データを最も近い重心へ割り当てる．

$$r_{i,\ell}^{(j)} = \begin{cases} 1 & \text{if } \ell = \arg\min_{k=1,\ldots,K} \ \|x_i - \mu_k^{(j-1)}\|^2, \\ 0 & \text{otherwise.} \end{cases} \tag{35}$$

2. **重心更新（Update）**：各クラスタの平均で重心を更新する．

$$\mu_\ell^{(j)} = \frac{\sum_{i=1}^N r_{i,\ell}^{(j)} x_i}{\sum_{i=1}^N r_{i,\ell}^{(j)}} \quad (\sum_i r_{i,\ell}^{(j)} > 0). \tag{36}$$

停止条件は $\max_\ell \|\mu_\ell^{(j)} - \mu_\ell^{(j-1)}\|^2 < \varepsilon$ 等とする．目的関数は反復で非増加となるが，局所解に収束するため初期化戦略（例：多点スタート，k-means++）が重要である．

以下は、K-平均法の R による実装例である。

Listing 5: K-平均法

```r
k_means <- function(x, K, max_iters = 10000, tol = 1e-6) {
```

```
    n <- nrow(x)
    d <- ncol(x)

    # ランダムに初期クラスタ中心を選択
    centroids <- x[sample(1:n, K), ]

    cluster_assignments <- rep(0, n)
    for (iter in 1:max_iters) {
        # 各データポイントを最も近いクラスタ中心に割り当て
        for (i in 1:n) {
            distances <- apply(centroids, 1, function(centroid) sum((x[i, ] - centroid)^2))
            cluster_assignments[i] <- which.min(distances)
        }

        # 新しいクラスタ中心を計算
        new_centroids <- matrix(0, nrow = K, ncol = d)
        for (k in 1:K) {
            points_in_cluster <- x[cluster_assignments == k, , drop = FALSE]
            if (nrow(points_in_cluster) > 0) {
                new_centroids[k, ] <- colMeans(points_in_cluster)
            } else {
                new_centroids[k, ] <- centroids[k, ]  # クラスタにポイントがない場合は中心を維持
            }
        }

        # 収束判定
        if (max(sqrt(rowSums((new_centroids - centroids)^2))) < tol) {
            # 各データポイントから割り当てられた中心までの距離の合計を計算
            total_distance <- 0
            for (i in 1:n) {
                centroid_idx <- cluster_assignments[i]
                distance <- sum((x[i, ] - centroids[centroid_idx, ])^2)
                total_distance <- total_distance + distance
            }
            break
        }

        centroids <- new_centroids
    }

    return(list(
        centroids = centroids,
        cluster_assignments = cluster_assignments,
        total_distance = total_distance
    ))
}
```

7　アルゴリズム比較

表や図を用いて複数手法の比較を行う。計算量・精度・安定性・実行時間の観点でまとめる。

8　結論

本章での結論と今後の課題を箇条書きでまとめる。

付録 A　使用コード一覧

主要スクリプトと入手先を列挙する。

- 実験コード（R）：https://github.com/<your-repo>
- データ生成スクリプト：`scripts/generate_data.jl`

付録 B　補足導出

必要な導出や補助的な数学的議論を載せる。

参考文献

参考文献

[1] 数理工学実験（2025 年度配布資料）.